LAPORAN UTS MACHINE LEARNING

Disusun oleh:

Giovano Alkandri 2341720096

PROGRAM STUDI D-IV TEKNIK INFORMATIKA

JURUSAN TEKNOLOGI INFORMASI

POLITEKNIK NEGERI MALANG

2025

Berikut adalah laporan hasil pengerjaan studi kasus analisis data dan clustering menggunakan unsupervised learning.

1. Dataset yang digunakan adalah Default of Credit Card Clients Dataset yanng didapatkan dari kaggle. Dataset tersebut memiliki jumlah sampel sebanyak 30 ribu baris dengan kolom sebanyak 25 termasuk ID. Untuk tipe data nya sendiri secara lengkap ada di bawah ini.

```
 #   Column                     Non-Null Count  Dtype
---  ------                     --------------  -----
 0   ID                         30000 non-null  int64
 1   LIMIT_BAL                  30000 non-null  float64
 2   SEX                        30000 non-null  int64
 3   EDUCATION                  30000 non-null  int64
 4   MARRIAGE                   30000 non-null  int64
 5   AGE                        30000 non-null  int64
 6   PAY_0                      30000 non-null  int64
 7   PAY_2                      30000 non-null  int64
 8   PAY_3                      30000 non-null  int64
 9   PAY_4                      30000 non-null  int64
 10  PAY_5                      30000 non-null  int64
 11  PAY_6                      30000 non-null  int64
 12  BILL_AMT1                  30000 non-null  float64
 13  BILL_AMT2                  30000 non-null  float64
 14  BILL_AMT3                  30000 non-null  float64
 15  BILL_AMT4                  30000 non-null  float64
 16  BILL_AMT5                  30000 non-null  float64
 17  BILL_AMT6                  30000 non-null  float64
 18  PAY_AMT1                   30000 non-null  float64
 19  PAY_AMT2                   30000 non-null  float64
 20  PAY_AMT3                   30000 non-null  float64
 21  PAY_AMT4                   30000 non-null  float64
 22  PAY_AMT5                   30000 non-null  float64
 23  PAY_AMT6                   30000 non-null  float64
 24  default.payment.next.month  30000 non-null  int64
```

2. Dataset akan dilakukan preprocessing agar siap untuk diolah, beberapa proses yang dilakukan sebagai berikut.
    a. Pengecekkan baris yang null, jika tidak ada maka bisa dilanjutkan.

```
Missing values tiap kolom
ID                          0
```

```
LIMIT_BAL                   0
SEX                         0
EDUCATION                   0
MARRIAGE                    0
AGE                         0
PAY_0                       0
PAY_2                       0
PAY_3                       0
PAY_4                       0
PAY_5                       0
PAY_6                       0
BILL_AMT1                   0
BILL_AMT2                   0
BILL_AMT3                   0
BILL_AMT4                   0
BILL_AMT5                   0
BILL_AMT6                   0
PAY_AMT1                    0
PAY_AMT2                    0
PAY_AMT3                    0
PAY_AMT4                    0
PAY_AMT5                    0
PAY_AMT6                    0
default.payment.next.month  0
RATIO                       0
Cluster                     0
PCA1                        0
PCA2                        0
Cluster_DB                  0
dtype: int64
```

b. Selanjutnya dilakukan normalisasi pada kolom fitur dan mengecualikan kolom yang tidak digunakan seperti ID dan default.patment.next.month dengan kode di bawah ini.

```
# normalisai
std = StandardScaler()
cols_to_scale = df.columns.difference(['ID',
'default.payment.next.month'])
df[cols_to_scale] = std.fit_transform(df[cols_to_scale])
```

c. Buat fitur baru dengan menghitung rasio antara BALANCE dan PURCHASES

```
# fitur baru ratio
bill_cols = [f'BILL_AMT{i}' for i in range(1, 7)]
df['RATIO'] = df['LIMIT_BAL'] / (df[bill_cols].mean(axis=1) +
1e-6)
df.head()
```

6	PAY_AMT1	PAY_AMT2	PAY_AMT3	PAY_AMT4	PAY_AMT5	PAY_AMT6	default.payment.next.month	RATIO
4	-0.341942	-0.227086	-0.296801	-0.308063	-0.314136	-0.293382	1	1.728340
6	-0.341942	-0.213588	-0.240005	-0.244230	-0.314136	-0.180878	1	0.579229
0	-0.250292	-0.191887	-0.240005	-0.244230	-0.248683	-0.012122	0	1.414385
9	-0.221191	-0.169361	-0.228645	-0.237846	-0.244166	-0.237130	0	8.854115
2	-0.221191	1.335034	0.271165	0.266434	-0.269039	-0.255187	0	2.284943

d. Lakukan seleksi fitur

```
# seleksi fitur (mencari kelompok pelanggan berdaraskan pola
penggunaan)
fitur = [
    'LIMIT_BAL', 'AGE', 'PAY_0', 'PAY_2', 'PAY_3', 'PAY_4',
'PAY_5', 'PAY_6',
    'BILL_AMT1', 'BILL_AMT2', 'BILL_AMT3', 'BILL_AMT4',
'BILL_AMT5', 'BILL_AMT6',
    'PAY_AMT1', 'PAY_AMT2', 'PAY_AMT3', 'PAY_AMT4',
'PAY_AMT5', 'PAY_AMT6', 'RATIO'
]
x = df[fitur]
x.head()
```

	LIMIT_BAL	AGE	PAY_0	PAY_2	PAY_3	PAY_4	PAY_5	PAY_6	BILL_AMT1	BILL_AMT
0	-1.136720	-1.246020	1.794564	1.782348	-0.696663	-0.666599	-1.530046	-1.486041	-0.642501	-0.6473
1	-0.365981	-1.029047	-0.874991	1.782348	0.138865	0.188746	0.234917	1.992316	-0.659219	-0.6667
2	-0.597202	-0.161156	0.014861	0.111736	0.138865	0.188746	0.234917	0.253137	-0.298560	-0.4938
3	-0.905498	0.164303	0.014861	0.111736	0.138865	0.188746	0.234917	0.253137	-0.057491	-0.0132
4	-0.905498	2.334029	-0.874991	0.111736	-0.696663	0.188746	0.234917	0.253137	-0.578618	-0.6113

3. Selanjutnya langkah untuk clustering KMeans dan DBSCAN.
   a. Cari k yang terbaik untuk clustering menggunakan elbow method

```
# cari K untuk kmeans
sse = []
```

```
k= range(1, 11)
for i in k:
    kmeans = KMeans(n_clusters=i, random_state=42)
    kmeans.fit(x)
    sse.append(kmeans.inertia_)

plt.plot(k, sse, 'bx-')
plt.xlabel('Jumlah K')
plt.ylabel('SSE')
plt.title('Metode Elbow')
plt.show()
```

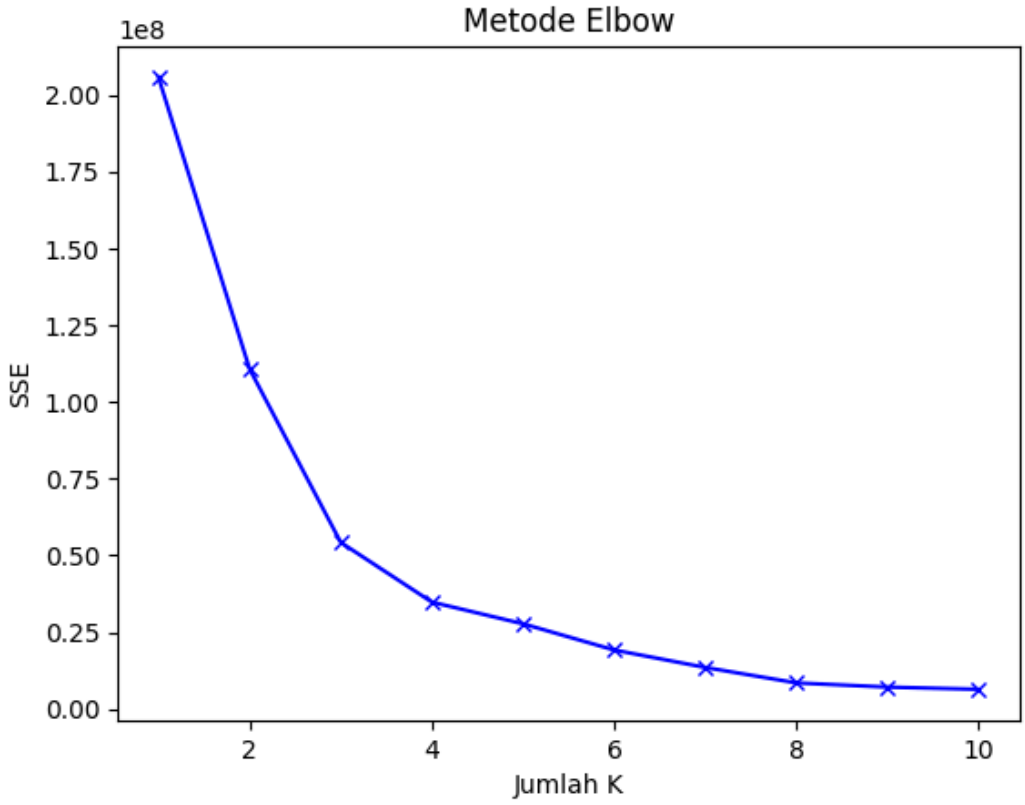

b. Hasi dari elbow method menunjukkan K terbaik ada pada k=3

c. Selanjutnya buat kmeans dengan k=3

```
#hasil menunjukkan 3 adalah k terbaik
kmeans = KMeans(n_clusters=3, random_state=42)
# fit dan prediksi
df['Cluster'] = kmeans.fit_predict(x)
```

d. Reduksi dimensi menggunakan PCA, lalu visualiasikan dalam bentuk 2D

```
pca = PCA(n_components=2)
pca_result = pca.fit_transform(x)
df['PCA1'] = pca_result[:, 0]
df['PCA2'] = pca_result[:, 1]
```

e. Tampilkan visual

```
plt.figure(figsize=(8, 6))
plt.scatter(df['PCA1'], df['PCA2'], c=df['Cluster'],
cmap='viridis', s=30, alpha=0.8)
centers = pca.transform(kmeans.cluster_centers_)
plt.scatter(centers[:, 0], centers[:, 1], c='red', s=200,
marker='X', label='Centroids', alpha=0.2)
plt.title('Visualisasi K-Means Clustering (K=4)',
fontsize=14)
plt.xlabel('PCA Component 1')
plt.ylabel('PCA Component 2')
plt.colorbar(label='Cluster')
plt.grid(True, alpha=0.3)
plt.show()
```

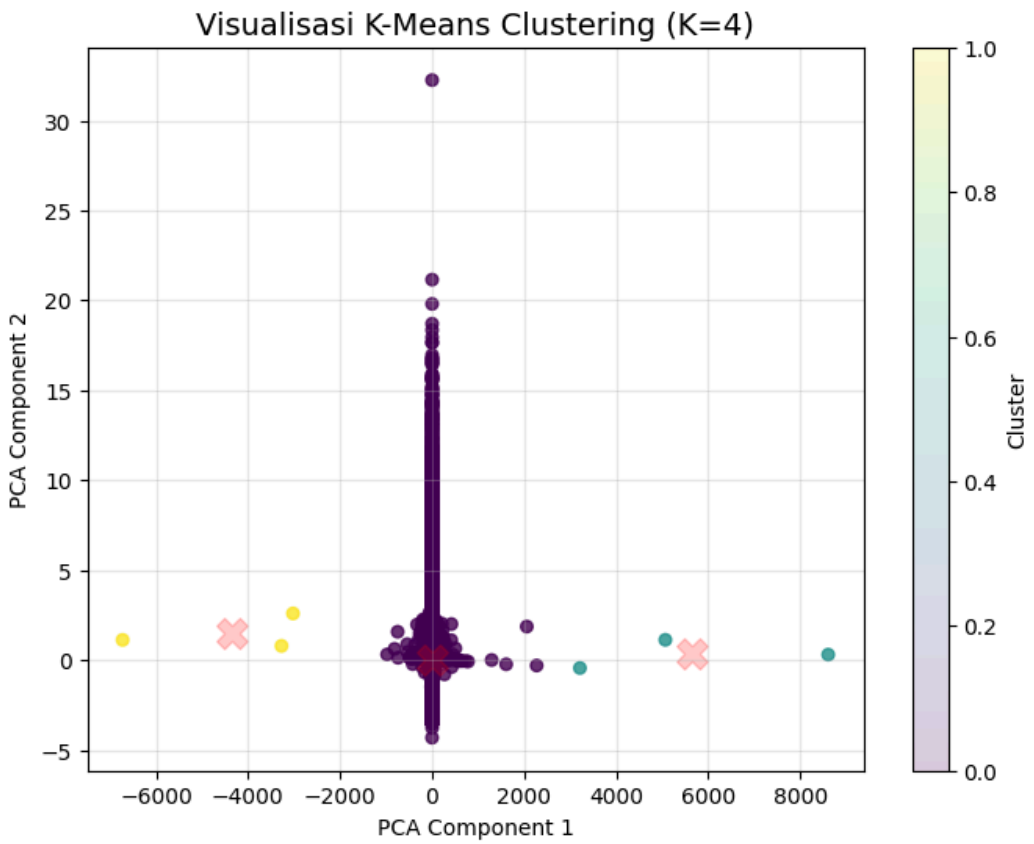

f. Cek jumlah data tiap cluster

```
print("Jumlah data tiap cluster:")
print(df['Cluster'].value_counts())
```

```
Jumlah data tiap cluster:
Cluster
0    29994
2        3
1        3
Name: count, dtype: int64
```

g. Tampilkan Shilouette score dan Dabies Bouldin score nya.

```
labels = df['Cluster']
print(f"Silhouette Coefficient: {metrics.silhouette_score(x,
labels): .3f}")
print(f"Davies Bouldin Coefficient:
{metrics.davies_bouldin_score(x, labels): .3f}")
print("==========================================================
")
```

```
Silhouette Coefficient:  0.997
Davies Bouldin Coefficient:  0.365
==========================================================
```

h. Cari eps terbaik untuk dbscan menggunakan kNN

```python
from sklearn.neighbors import NearestNeighbors
neigh = NearestNeighbors(n_neighbors=5)
nbrs = neigh.fit(x)
distances, indices = nbrs.kneighbors(x)
distances = np.sort(distances[:,4], axis=0)
plt.plot(distances)
plt.xlabel('Data Points sorted by distance')
plt.ylabel('5th Nearest Neighbor Distance')
plt.title('k-NN Distance Plot for DBSCAN eps selection')
plt.ylim(0, 10)
plt.grid(True, alpha=0.3)
plt.show()
```

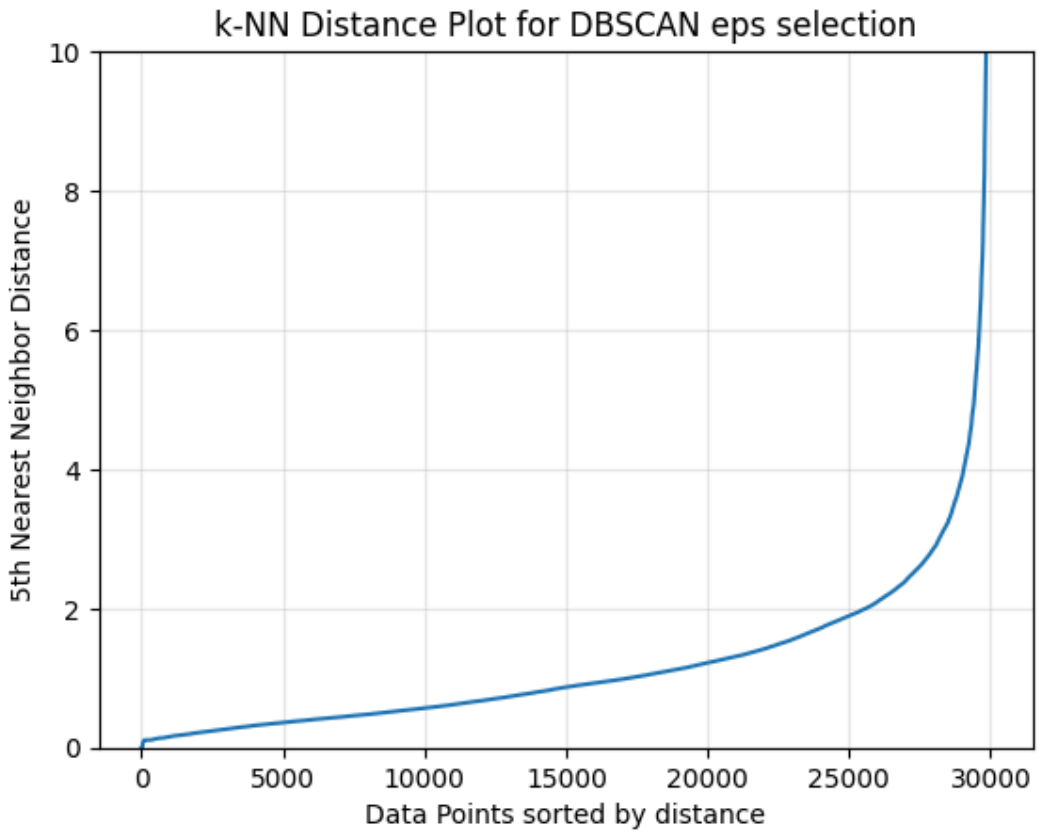

i. Dari grafik tersebut, saya melakukan eksperimen mencari shilouette score dan Davies Bouldin score yang optimal dengan membandingkan eps 1.5, 2, 2.5, 3 dan min_samples 5, 10, 15, 20, 25.

```
def perbandingan_score_dbscan(eps, min_samples):
    db = DBSCAN(eps=eps, min_samples=min_samples).fit(x)
    labels = db.labels_

    n_clusters_ = len(set(labels)) - (1 if -1 in labels else
0)
    n_noise_ = list(labels).count(-1)

    print(f"DBSCAN dengan eps={eps} dan
min_samples={min_samples}")
    print("estimasi jumlah kluster: %d" % n_clusters_)
    print("estimasi jumlah noise: %d" % n_noise_)
    print(f"Silhouette Coefficient:
{metrics.silhouette_score(x, labels): .3f}")
    # siluet max 1
    print(f"Davies Bouldin Coefficient:
{metrics.davies_bouldin_score(x, labels): .3f}")
    # davies bouldin lebih baik mendekati 0

print("=====================================================
")

perbandingan_score_dbscan(1.5, 5)
perbandingan_score_dbscan(1.5, 10)
perbandingan_score_dbscan(1.5, 15)
perbandingan_score_dbscan(1.5, 20)
perbandingan_score_dbscan(1.5, 25)
perbandingan_score_dbscan(2, 5)
perbandingan_score_dbscan(2, 10)
perbandingan_score_dbscan(2, 15)
perbandingan_score_dbscan(2, 20)
perbandingan_score_dbscan(2, 25)
perbandingan_score_dbscan(2.5, 5)
perbandingan_score_dbscan(2.5, 10)
perbandingan_score_dbscan(2.5, 15)
```

```
perbandingan_score_dbscan(2.5, 20)
perbandingan_score_dbscan(2.5, 25)
perbandingan_score_dbscan(3, 5)
perbandingan_score_dbscan(3, 10)
perbandingan_score_dbscan(3, 15)
perbandingan_score_dbscan(3, 20)
perbandingan_score_dbscan(3, 25)
```

j. Dari eksperimen tersebut, hasil yang paling optimal adalah eps 3 dan min samples 25

```
=========================================================
DBSCAN dengan eps=3 dan min_samples=25
estimasi jumlah kluster: 4
estimasi jumlah noise: 2001
Silhouette Coefficient:  0.392
Davies Bouldin Coefficient:  7.023
=========================================================
```

k. Buat cluster DBSCAN dengan eps 3 dan min_samples 25

```
db = DBSCAN(eps=3, min_samples=25).fit(x)
df['Cluster_DB'] = db.labels_

labels = df['Cluster_DB']
core_samples_mask = np.zeros_like(labels, dtype=bool)
core_samples_mask[db.core_sample_indices_] = True
n_clusters_ = len(set(labels)) - (1 if -1 in labels else 0)
n_noise_ = list(labels).count(-1)
```

l. Reduksi dimensi menggunakan PCA, lalu visualiasikan dalam bentuk 2D

```
pca = PCA(n_components=2)
pca_result = pca.fit_transform(x)
```

m. Visualisasikan hasilnya

```
plt.figure(figsize=(10, 8))
colors = plt.cm.Spectral(np.linspace(0, 1, len(set(labels))))
```

```
for k, col in zip(set(labels), colors):
    if k == -1:
        # Black used for noise
        col = [0, 0, 0, 1]

    class_member_mask = labels == k

    # Plot core samples
    xy = pca_result[class_member_mask & core_samples_mask]
    plt.scatter(xy[:, 0], xy[:, 1],
                s=140,
                c=[col],
                marker='o',
                label=f'Cluster {k}' if k != -1 else 'Noise')

    # Plot non-core samples
    xy = pca_result[class_member_mask & ~core_samples_mask]
    plt.scatter(xy[:, 0], xy[:, 1],
                s=60,
                c=[col],
                marker='o',
                alpha=0.5)

plt.title(f'Estimated number of clusters: {n_clusters_}')
plt.xlabel('First Principal Component')
plt.ylabel('Second Principal Component')
plt.legend()
plt.grid(True, alpha=0.3)
plt.show()
```

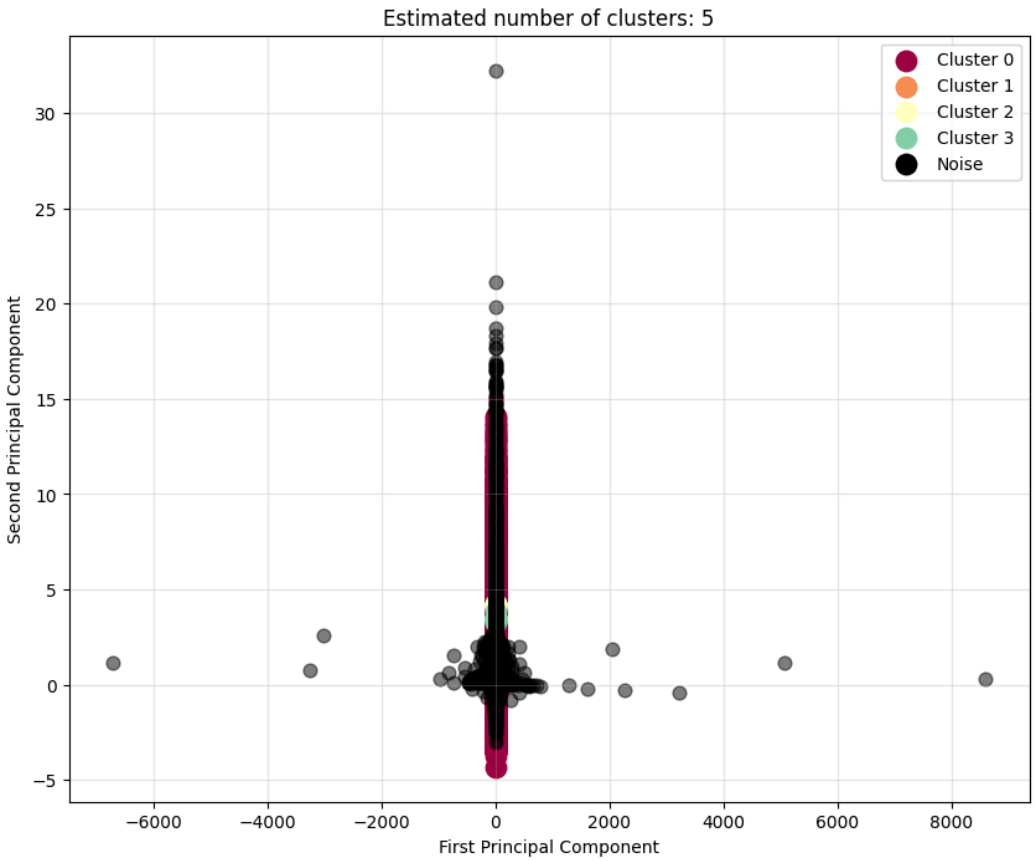

4. Selanjutnya langkah untuk ANN.
    a. Convert dan simpan jumlah fitur

```
x = df[fitur].copy()
data_matrix = x.values.astype('float32') # convert ke float32
n_features = data_matrix.shape[1] # dimensi nya 21
```

    b. Build annoy

```
print(f"indeks Annoy dengan {n_features} dimensi")
start = time.time()
t = AnnoyIndex(n_features, 'euclidean')
for i in range(len(data_matrix)):
    t.add_item(i, data_matrix[i])

# 10 tree untuk balancing akurasi dan kecepatan
t.build(10)
```

```
print("build done in", time.time() - start, "seconds")
```

```
indeks Annoy dengan 21 dimensi
build done in 0.10225987434387207 seconds
```

c. Buat 5 titik random lalu jalankan proses query

```
# 5 titik random
num_queries = 5
query_indices = random.sample(range(len(data_matrix)),
num_queries)
k_neighbors = 6 # jumlah tetangga terdekat yang dicari

print(f"\nMelakukan Query pada {num_queries} titik acak
(mencari {k_neighbors} tetangga terdekat):")

results = {}
for q_idx in query_indices:
    # include_distances=True untuk mendapatkan jarak
    neighbor_indices, distances = t.get_nns_by_item(q_idx,
k_neighbors, search_k=-1, include_distances=True)

    # save
    query_results = {
        'neighbor_index': neighbor_indices,
        'distance': distances
    }
    results[q_idx] = query_results

for q_idx, res in results.items():
    print(f"\n--- Query Titik Index: {q_idx} ---")
    print("Vektor Data Awal (head):",
x.iloc[q_idx].head().to_dict())
    print(f"Tetangga Terdekat (Index) dan Jarak:")

    # df hasil
    df_results = pd.DataFrame({
        'Index_Tetangga': res['neighbor_index'],
        'Jarak_Euclidean': res['distance'],
```

```
        'Cluster_Tetangga': df.loc[res['neighbor_index'],
'Cluster'].values
    })
    # delete entri pertama jika query sendiri (jarak = 0)
    df_results = df_results[df_results['Jarak_Euclidean'] >
1e-6]

    print(df_results)
```

d. Hasil dari query

Melakukan Query pada 5 titik acak (mencari 6 tetangga terdekat):

--- Query Titik Index: 26145 ---
Vektor Data Awal (head): {'LIMIT_BAL': 0.4818331099937201, 'AGE': 1.3576522914289104, 'PAY_0': 0.01486052289860516, 'PAY_2': 0.11173610381332785, 'PAY_3': 0.13886479544680802}
Tetangga Terdekat (Index) dan Jarak:

	Index_Tetangga	Jarak_Euclidean	Cluster_Tetangga
1	26867	2.033188	0
2	22792	2.094576	0
3	18009	2.245838	0
4	20800	2.270676	0
5	18247	2.318572	0

--- Query Titik Index: 3741 ---
Vektor Data Awal (head): {'LIMIT_BAL': -0.982572216860082, 'AGE': 1.249165952268024, 'PAY_0': 0.9047121934737644, 'PAY_2': 1.782348171792314, 'PAY_3': 1.809921299018505}
Tetangga Terdekat (Index) dan Jarak:

	Index_Tetangga	Jarak_Euclidean	Cluster_Tetangga
1	12819	2.172710	0
2	8048	2.327822	0
3	13300	2.511787	0
4	21380	2.857340	0
5	26702	2.940989	0

--- Query Titik Index: 8849 ---
Vektor Data Awal (head): {'LIMIT_BAL': -0.5201284294325655, 'AGE': 2.225543004716, 'PAY_0': 0.01486052289860516, 'PAY_2': 0.11173610381332785, 'PAY_3': 0.13886479544680802}
Tetangga Terdekat (Index) dan Jarak:

	Index_Tetangga	Jarak_Euclidean	Cluster_Tetangga

```
1          23813        0.596019              0
2          18235        0.634090              0
3          16468        0.925201              0
4          26482        0.969810              0
5           5292        1.198129              0

--- Query Titik Index: 4546 ---
Vektor Data Awal (head): {'LIMIT_BAL': 0.4047591454224674, 'AGE':
-1.2460198484323588, 'PAY_0': 1.7945638640489239, 'PAY_2':
2.617654205781807, 'PAY_3': 1.809921299018505}
Tetangga Terdekat (Index) dan Jarak:
   Index_Tetangga  Jarak_Euclidean  Cluster_Tetangga
1          20464         1.367698              0
2           9731         1.379305              0
3           3715         1.711618              0
4          18757         1.952727              0
5          22107         1.981912              0

--- Query Titik Index: 4543 ---
Vektor Data Awal (head): {'LIMIT_BAL': -0.9054982522888293, 'AGE':
-1.0290471701105863, 'PAY_0': 0.9047121934737644, 'PAY_2':
1.782348171792314, 'PAY_3': 0.13886479544680802}
Tetangga Terdekat (Index) dan Jarak:
   Index_Tetangga  Jarak_Euclidean  Cluster_Tetangga
1           1554         0.596019              0
2          10890         1.283680              0
3           5549         1.869402              0
4          21837         1.908792              0
5          25165         1.931633              0
```

5. Kesimpulan

   a. Perbedaan hasil KMeans dan DBSCAN, mana yang lebih baik diantara kedua model ini dan jelaskan jawaban anda

      Jawab: dari hasil pengerjaan sebelumnya, DBSCAN terlihat memberikan hasil yang lebih baik untuk dataset ini. Algoritma DBSCAN memiliki bawaan otomatis yang mendeteksi outlier atau noise. Pada bentuk cluster yang padat dan memanjang secara vertikal, KMeans cenderung menggabungkan struktur ini menjadi klaster yang besar sheingga mengabaikan potensi sub-struktur. Sedangkan DBSCAN bisa memisahkan cluster apdat ini menjadi beberapa cluster

berdasarkan perbedaan jarakk terdekat, dan dengan akurat menemukan outlier sebagai noise.

b. Nilai metrik terbaik (Silhouette, DBI).

i. KMeans

```
Silhouette Coefficient:  0.997
Davies Bouldin Coefficient:  0.365
```

ii. DBSCAN

```
DBSCAN dengan eps=3 dan min_samples=25
estimasi jumlah kluster: 4
estimasi jumlah noise: 2001
Silhouette Coefficient:  0.392
Davies Bouldin Coefficient:  7.023
```

iii. Kesimpulannya nilai metrik (Shilouette dan DBI) terbaik ada pada KMeans, dimana skor silhouette semakin baik jika mendekati 1 dan skor DBI mendekati 0.

c. Hasil query Annoy: apakah tetangga yang ditemukan termasuk dalam cluster yang sama? Jelaskan jawaban anda.

Jawab: Tetangga yang ditemukan termasuk dalam cluster yang sama. Hal itu dapat dilihat dari tetangga dari salah satu titik ini. Hasil dari Annoy nearest neighbors menunjukkan konsistensi dengan hasil klasterisasi KMeans. Nearest neighbors yang teridentifikasi memiliki karakteristik yang mirip dan tergolong dalam cluster yang sama.

```
--- Query Titik Index: 4543 ---
Vektor Data Awal (head): {'LIMIT_BAL': -0.905498252288
Tetangga Terdekat (Index) dan Jarak:
   Index_Tetangga  Jarak_Euclidean  Cluster_Tetangga
1            1554         0.596019                 0
2           10890         1.283680                 0
3            5549         1.869402                 0
4           21837         1.908792                 0
5           25165         1.931633                 0
```